

基于机器学习与相关系数的玻璃文物的成分鉴别分析

摘 要

本文研究的古代玻璃制品的成分分析与鉴别，实则是评价类问题与预测类问题的结合。

针对问题一，为找出玻璃文物的表面风化与其玻璃类型、纹饰和颜色的关系，采用斯皮尔曼方法对附件 1 中的数据进行相关性分析，得出表面是否风化与玻璃种类相关性最大，纹饰，颜色相关性不大的关系。为找出文物样品表面有无风化化学成分含量的统计规律，采用 spss 中的独立样本 t 检验的方法，得出相关数据，画成频率直方图进行比较，得出高钾玻璃在风化后主要化学成分含量呈下降趋势，铅钡类玻璃在风化后主要化学成分含量呈上升趋势的规律。为预测其风化前的化学成分含量，对附件 2 中的数据进行预处理，得到相应坐标，用拉格朗日插值法构造出相应曲线，完成对风化前化学成分含量的预测（见表 3）。

针对问题二，为找出高钾玻璃、铅钡玻璃的分类规律，采用主成分分析法，分析结果，得出高钾玻璃、铅钡玻璃的分类规律：含 SiO_2 、 K_2O 较多的为高钾玻璃，含 PbO 、 BaO 较多的为铅钡玻璃。为选择合适的化学成分对每个类别进行亚类划分，采用 K 均值聚类分析的方法，通过分析 k 值与离差平方和关系曲线寻找合适的 K 值，最终找出 7 个聚类中心，将文物样本分为七种亚类。最后利用控制变量法改变 k 值等严格验证了分类结果的合理性。

针对问题三，为鉴别不同文物的所属类型，以欧式距离为度量，利用最近邻算法，求出样本相对于各个聚类中心的距离，被分类文物与哪个中心的距离近，就判定为属于哪个亚类。最后其敏感性在于待测文物完全取决于与其最近的类别，对于这个类别很敏感，我们对此进行检验，大部分结果具有正确性。

针对问题四，为分析不同类别的玻璃文物样品其化学成分之间的关联关系，用皮尔逊相关系数分别去分析问题三中亚类划分出的七种类型，并根据皮尔逊系数分析出各个化学成分之间的相关性。之后在将七个亚类皮尔逊系数矩阵，利用化学元素差异折线图将操作结果可视化进行比较，得出不同类别之间的化学成分关联关系的差异性。

本文采用多种算法，建立多种数学模型与生活实际紧密联系，结合实际情况对问题进行求解，使模型具有更好的推广性和通用性。

关键词：斯皮尔曼相关系数分析；独立样本 t 检验；主成分分析法；k 均值聚类算法；皮尔逊系数分析

1. 问题重述

玻璃作为证明早期贸易往来的凭证，距今 2500 年左右从西亚和埃及等地区传入我国。我国古代匠人经创造性转化、创新性发展研制出外观相似、化学成分不同的古代玻璃。在烧制过程中加入铅矿石的铅钡玻璃，被认为是我国本土化的玻璃品种。以含钾量高的物质烧制而成的钾玻璃，主要流行于中亚、东南亚以及我国岭南等区域。古代玻璃易受外部环境影响，化学成分发生改变，从而影响对其所属类别的正确判断。现有一批关于我国古代玻璃制品的数据，大致分为高钾玻璃和铅钡玻璃两种类型。附件表单 1 给出了这些玻璃制品的分类信息，附件 2 给出其主要成分的所占比例，各成分比例累加和应为 100%（受科技水平有限等原因累加和于 85%~105%之间为有效数值）。

试就依据附件中的相关信息，建立数学模型分析以下问题：

（1）对这些玻璃文物的玻璃类型、花纹、装饰以及颜色与表面风化的关系进行分析。结合玻璃文物类型，分析其表面有无风化化学成分含量的统计规律，之后根据风化点的数据，预测风化前的化学成分含量。

（2）依照附件分析高钾玻璃和铅钡玻璃的分类规律。对于每个种类进行亚类划分，给出详细的划分方法和划分结果，并对于分类结果进行合理性和敏感性分析。

（3）对附件表单 3 中未知类别玻璃文物进行化学成分分析并鉴别其类型，对分类结果进行敏感性分析。

（4）针对不同类别的玻璃文物，分析其化学成分之间的关联，并比较其差异性。

2. 问题分析

2.1. 问题一的分析

可将问题一分为三个小问：

（1）对于这些玻璃文物的玻璃类型、纹饰以及颜色与表面风化的关系问题，我们分别将表面是否风化与颜色、纹饰、玻璃类型一一对照建立条形统计图进行统计，建立斯皮尔曼相关系数分析^[1]的数学模型。

（2）结合玻璃文物类型，我们利用独立样本 t 检验^[2]得出相关数据，分析其表面有无风化化学成分含量的统计规律。

（3）根据风化点的检测数据（类型、颜色）分化程度不同的点，通过拉格朗日插值法^[3]，预测之前的化学含量。

2.2. 问题二的分析

可将问题二分为三个小问：

（1）关于分析高钾玻璃、铅钡玻璃的分类规律问题，我们采用主成分分析法相关的数学模型^[4]，将样本可视化。

（2）对于每个类别选择合适的进行亚类划分，我们采用 k 均值聚类算法^[5]的思想，计算出聚类结果和聚类后的类中心得出划分结果。

（3）通过控制变量法等方法改变 k 值，推测其合理性和敏感性。

2.3. 问题三的分析

可将问题三分为两个小问：

- （1）对未知类别玻璃文物的化学成分分析其实是问题 2 的衍生，结合问题 2 的聚类中心，以简单易懂的欧式距离为度量，利用最近邻算法^[6]来确定亚类。
- （2）对分类结果的敏感性进行分析实质问题是合理性敏感性分析，可通过控制变量法等实现。

2.4. 问题四的分析

可将问题四分为两个小问：

- （1）分析不同类别的玻璃文物样品其化学成分之间的关系，我们运用统计学中的皮尔逊相关系数^[7]两两探究化学元素之间的关联。
- （2）对于比较不同类别的化学成分关联关系的差异性，可将操作结果可视化利用折线图进行比较。

3. 模型假设

- 1. 有效样本数据作为实验数据，无效样本数据不会干扰实验结果。
- 2. 部分实验数据有缺失的样本视为无效样本（颜色等）。
- 3. 对于表单二的样本只检测部分区域视为全部区域。
- 4. 对于一个文物多个区域不均匀范围检测视为检测范围均匀（如一个样本检测两个区域视为各检测半个样本）。
- 5. 风化过程中纹理不会影响化学成分的改变，只会影响风化的速度。
- 6. 仅考虑问题中的核心因素，不考虑次要因素的影响（如样本不会被周边环境污染等）。
- 7. 对于表面发生风化的文物，若其文物采样点没有提到“未风化点”，视为风化点检测数据，进行插值预测
- 8.

4. 模型的建立与求解

4.1. 问题一模型的建立与求解

4.1.1. 表面风化与颜色、纹饰、玻璃类型的关系

第一步：将数据进行预处理，我们筛选剔除无效数据（见附件 1 有效数据的统计，标红的为无效数据）选择有效数据（见表 1）。

表 1 有效数据所占主要成分比例

文物编号	所占主要成分比例	文物编号	所占主要成分比例	文物编号	所占主要成分比例
01	97.61	23 未风化点	96.5	43 部位 1	94.68
02	99.89	24	98.88	43 部位 2	96.67
03 部位 1	100	25 未风化点	97.06	44 未风化点	99.12
03 部位 2	98.88	26	99.82	45	98.34
04	96.06	26 严重风化点	99.89	46	98.63
05	96.51	27	98.81	47	97.26

文物编号	所占主要成分比例	文物编号	所占主要成分比例	文物编号	所占主要成分比例
06 部位 1	98.92	28 未风化点	98.69	48	99.17
06 部位 2	98.84	29 未风化点	99.88	49	95.5
07	99.7	30 部位 1	97.95	49 未风化点	98.24
08	99.82	30 部位 2	98.7	50	90.17
08 严重风化点	98.24	31	98.43	50 未风化点	96.94
09	99.77	32	98.66	51 部位 1	95.33
10	99.81	33	99.96	51 部位 2	91.7
11	95.39	34	97.52	52	94.08
12	99.57	35	96.21	53 未风化点	98.25
13	98.14	36	97.63	54	99.67
14	99	37	99.98	54 严重风化点	96.92
16	98.41	38	98.57	55	96.38
18	97.25	39	98.76	56	92.24
19	98.76	40	98.57	57	92.47
20	88.41	41	93.71	58	98.76
21	98.52	42 未风化点 1	98.01		
22	100	42 未风化点 2	97.9		

为了使数据可视化，我们利用了 python 的 matplotlib.pyplot 库，绘制了扇形图可以分别看出玻璃种类（见图 1）、颜色（见图 2）、纹饰（见图 3）所占样本比例。




图 1 玻璃种类扇形




图 2 颜色扇形图




图 3 纹饰扇形图




图 4 表面风化关系图

第二步：我们发现问题一的第一小问是一对多的关系（图 4），探究变量关系且属于等级变量性质的具有线性关系的数据资料适用于斯皮尔曼相关系数模型。

斯皮尔曼相关系数算法步骤：

假设两个长度为 N 的向量 X 和 Y ，即 X 和 Y 中包含 N 个元素，计算两个向量 X 和 Y 的相关性。

Step1: 将两个列向量 X 和 Y 对应的元素 X_i 和 Y_i 转换为在各自列向量中的排名，记为 $R(X_i)$ 和 $R(Y_i)$ 。

Step2: 根据下面公式，计算两个列向量 X 和 Y 中对应元素的 $R(X_i)$ 和 $R(Y_i)$ 之间的差异 d ，并相加

$$d = \sum_{i=1}^N |R(X_i) - R(Y_i)|^2 \quad (1)$$

Step3: 最后，根据下面公式计算出两个列向量之间的相关性 R_s

$$R_s = 1 - \frac{6 \times d}{N \times (N^2 - 1)} \quad (2)$$

根据斯皮尔曼相关系数利用 python 编程（程序见附录 3）得到了表面是否风化与玻璃种类、颜色、纹饰相关性数据（见表 2 保留三位小数）

表 2 斯皮尔曼相关系数表

	纹饰	玻璃种类	颜色
表面风化	0.048	0.316	0.070

由表 2 可知表面是否风化与玻璃种类相关性最大，纹饰，颜色相关性不大。

4.1.2. 文物样品表面有无风化化学成分含量的统计规律

面对样品表面有无风化这两个独立分组对它进行几个因变量的均值进行比较使用，我们采用独立样本 t 检验（程序见附件 1.1.1 和 1.1.2，操作步骤见图 5）。




图 5 独立样本检验操作步骤

高钾玻璃的相关检验数据(见附件 1.1.1)铅钡玻璃的相关检验数据(见附件 1.1.2)。

结合独立样本 t 检验数据（如个案数、平均值、标准差）分别得出文物样品高钾有风化、高钾无风化、铅钡有风化、铅钡无风化的简单直方图（见图 6、图 7、图 8、图 9）。




图 6 高钾玻璃有风化简单直方图



图 7 高钾玻璃无风化简单直方图




图 8 铅钡玻璃有风化简单直方图



图 9 铅钡玻璃无风化简单直方图

由频率分布直方图可以直观的看出高钾玻璃在风化后主要化学成分含量呈下降趋势；铅钡类玻璃在风化后主要化学成分含量呈上升趋势。

4.1.3. 根据风化点检测数据，预测其风化前的化学成分含量

面对预测类问题可以转化为风化前的缺失值处理，拉格朗日插值法有着简单、方便、易实现的特性，所以采用拉格朗日插值法（程序见附录 4）预测风化前的化学成分含量可以取得较理想的结果。

操作步骤如下：

Step1：求已知 $n+1$ 个点的插值基函数表达式为：

$$l_j(x) = \prod_{i=0, i \neq j}^n \frac{x-x_i}{x_j-x_i} = \frac{x-x_0}{x_j-x_0} \dots \frac{x-x_{j-1}}{x_j-x_{j-1}} \frac{x-x_{j+1}}{x_j-x_{j+1}} \dots \frac{x-x_n}{x_j-x_n} \quad (3)$$

Step2：求已知 $n+1$ 个点对的拉格朗日插值多项式 $L(x)$ 表达式为：

$$Lx = \sum_{j=0}^n y_j l_j(x) \quad (4)$$

Step3：将缺失函数值对应点代入插值多项式得到缺失值的近似值（即风化前的化学成分含量）。

我们选择大多数文物中存在的化学成分，分别求插值函数，进行预测得到实验结果（见表3）。

表3 预测风化前的化学成分含量

文物采样点	二氧化硅 (SiO ₂)	氧化铝 (Al ₂ O ₃)	五氧化二磷 (P ₂ O ₅)	氧化铜 (CuO)	文物采样点	二氧化硅 (SiO ₂)	氧化铝 (Al ₂ O ₃)	氧化铜 (CuO)
02	61.28	4.55	0.01	0.53	39	60.12	2.72	1.46
07	63.76	10.6	4.34	2.36	41	65.91	1.44	0.65
08	65.91	3.11	1.63	17.78	43	48.01		
09	74.42	4.78	0.68	2.94	49	60.54		
10	76.73	6.19	1.1	3.28	50	68.34	21.07	
11	55.21	4.79	2.66	1.17	52	51.54	3.06	0.11
12	69.37	3.93	1.17	3.87	54	37.36	5.44	7.8
22	61.6	7.5	0.94	3.27	56	56.01	20.52	
26	31.94	1.59	0.14	43.38	57	45.04		1.1
27	65.91	6.44	0.79	2.18				
34	75.51	2.35	0.13	0.47				
36		1.86						
38	43.4	39.8		41				

4.2. 问题二模型的建立与求解

4.2.1. 分析高钾玻璃、铅钡玻璃的分类规律

探究分类规律问题，可以转化为特征提取方法描述样本特征以及区别。因此我们小组使用主成分分析法。这一方法利用正交变换把由线性相关变量表示的观察数据转换为少数几个由线性无关变量表示的数据，线性无关的变量称为主成分即重要特征。具体操作步骤如下：

Step1 求协方差矩阵 $\sum$ 。

Step2 求 $\sum$ 的特征值，特征向量 λ ， α 。

Step3 归一化所有的 α ，使得 $\alpha \alpha_1^T = 1$

Step4 $A = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}$

Step5 $T = A (x_i - \bar{x})$

建立主成分相关的数学模型（程序见附录 5）求出四种类别的主成分贡献率（见表 4 结果保留两位小数）累加和大于 90%作为主成分贡献率。

表 4 各类别主成分贡献率							
类别	主成分贡献率						
高钾无	0.77	0.12	0.05	0.03	0.01	0.01	0.01
风化	0.00	0.00	0.00	0.00	0.00		
高钾有	0.78	0.21	0.02	0.01	0.00	0.00	
风化							
铅钡无	0.75	0.21	0.03	0.01	0.00	0.00	0.00
风化	0.00	0.00	0.00	0.00	0.00	0.00	
铅钡有	0.70	0.23	0.04	0.01	0.01	0.01	0.00
风化	0.00	0.00	0.00	0.00	0.00	0.00	0.00

利用选取的主成分贡献率进行计算得出调整后的主成分系数（见表 5 结果保留两位小数，标红的为较大的主成分系数值得我们重点关注）。

表 5 调整后的主成分系数							
类别	调整后的主成分系数						
高钾无	0.91	-0.06	-0.28	-0.23	-0.01	-0.14	-0.09
风化第一组	-0.08	-0.01	-0.00	-0.02	-0.00	0.03	-0.00
高钾无	-0.18	-0.15	-0.68	-0.28	0.11	0.41	0.31
风化第二组	0.02	0.14	0.30	0.01	-0.043	-0.01	
高钾无	-0.02	-0.02	0.49	-0.68	0.10	0.30	-0.10
风化第三组	-0.31	-0.04	-0.05	0.25	0.01	0.13	-0.019
高钾有	0.85	0.00	0.13	-0.22	-0.10	-0.43	0.01
风化第一组	-0.13	0.00	0.00	-0.06	0.00	0.00	0.00

类别	调整后的主成分系数							
高钾有风化第二组	0.08	0.00	0.22	0.13	0.19	0.39	0.05	
铅钡无风化第一组	-0.85	0.00	0.00	-0.14	0.00	0.00	0.00	
铅钡无风化第二组	0.88	-0.00	-0.01	-0.04	0.00	-0.02	-0.01	-
铅钡有风化第一组	0.07	-0.35	-0.31	-0.02	-0.01	-0.01	0.01	
铅钡有风化第二组	0.12	0.02	0.00	0.10	0.02	-0.05	0.02	-0.19
	0.81	-0.52	-0.13	0.00	0.01	-0.02		
	0.80	0.05	0.00	-0.03	0.00	0.09	0.00	
	-0.03	-0.56	-0.14	-0.10	-0.01	0.00	-0.06	
	-0.29	0.01	-0.00	-0.01	-0.02	-0.04	-0.02	
	0.13	-0.62	0.68	-0.01	-0.00	-0.00	0.22	

根据相对应的化学元素规律（如每排第一个对应为附件中的第一个化学元素二氧化硅(SiO_2)，第二个对应为附件中的第二个化学元素氧化钠(Na_2O)）得出高钾玻璃、铅钡玻璃的分类规律：含 SiO_2 、 K_2O 较多的为高钾玻璃，含 PbO 、 BaO 较多的为铅钡玻璃。

4.2.2. 每个类别选择合适的进行亚类划分，给出划分结果

该题为了对种类其进行科学的亚类因此需排除外界环境的干扰，我们特此选用无风化样品作为本题样本数据。

文物样本对象较多、计算量大，聚类结果复杂不便分析，为此我们选取动态聚类法中的 K 均值聚类算法（程序见附录 6），流程图（见图 10）




图 10 k 均值聚类流程图

划分利用簇内离差平方和拐点法，在不同的 k 值下计算簇内离差平方和

$$J_k = \sum_{i=1}^k \sum_{\omega \in G_i} \|\omega - m_i\|^2 \quad (5)$$

代入样本数值根据曲线选取斜率变化大的点作为 k 值，确定最佳簇数 k 值（见图 11、图 12），高钾玻璃的 k 值为 4，铅钡玻璃的 k 值为 3。




图 11 铅钡玻璃 k 值与离差平方和关系曲线




图 12 高钾玻璃与离差平方和的关系曲线

采用 k 均值聚类算法得出类别标签（见表 6）和聚类中心（见表 7 保留两位小数），为方便处理类别标签采取+1 操作进行分组。

表 6 类别标签

类别	类别标签											
高钾无风化	0	1	2	0	2	0	2	2	2	0	1	3
铅钡无风化	0	0	2	2	1	1	1	1	1	1	2	2

表 7 文物样本的相关聚类中心

类别	聚类中心							
高钾一组	67.01	0.53	10.39	5.43	1.23	6.93	1.65	
	2.41	0.08	0.35	1.54	0.04	0.00	0.19	
高钾二组	83.26	0.00	7.31	1.01	0.77	3.56	0.00	0.39
	0.13	0.00	1.01	0.04	1.18	0.00		
高钾三组	60.92	1.25	11.16	7.11	1.05	7.69	2.84	
	3.15	0.68	0.77	1.51	0.06	0.00	0.09	

类别	聚类中心							
高钾四组	76.68	0.00	00	4.71	1.22	6.19	2.37	3.28
	1.00	1.97	1.10	0.00	0.00	0.00		
铅钡一组	34.65	0.00	0.36	0.24	0.00	3.52	0.76	
	6.62	19.22	24.89	2.95	0.46	0.00	0.00	
铅钡二组	66.41	0.44	0.12	0.8	0.44	2.83	0.96	
	0.79	17.96	6.47	0.63	0.14	0.00	0.61	
铅钡三组	45.41	1.47	0.39	2.15	0.75	3.5	0.97	
	0.46	32.11	9.58	0.41	0.42	0.17	0.00	

最后得出亚类划分结果（以 SiO_2 从大到小排列见表 8）

表 8 亚类划分结果

玻璃类型	亚类	说明
高钾玻璃	G2	本类中 SiO_2 占绝大多数（约 83.23%），一部分成分为 0， SiO_2 含量与其他差异显著
	G3	本类中 SiO_2 占半数多（约 60.92%），含有一部分 K_2O ，其余化学元素含量几乎无 0
	G1	本类中 SiO_2 占半数多（约 67.01%），含有一部分 K_2O 、 Al_2O_3
	G4	本类中 SiO_2 占大部分（约 76.68%），一部分成分为 0， SiO_2 含量与其他差异显著
铅钡玻璃	Q1	本类中 SiO_2 占多数（约 34.65%），其次是 BaO （约 24.89%）一部分成分为 0， SiO_2 含量与其他差异不显著
	Q2	本类中 SiO_2 超半数，几乎无 0
	Q3	SiO_2 占近一半（约 45.41%）， PbO 也占有一部分（约 32.11%）

4.2.3. 对分类结果进行敏感性和合理性分析

第一步：首先，K 均值算法简单高效，属于收敛算法，没有特别复杂的模型参数，在实际生活中有广泛应用。其宗旨为：类间距离最大化，类内距离最小化。该算法在无监督的环境下聚类，能对数据进行更精确的划分，符合题意“亚类划分”。并且我们已经通过计算簇内离差平方和来确定 k，有利于算法的进行。现分析其缺点，K 均值算法对噪声点敏感，这种数据点可能导致聚类效果差。经过分析观察，数据中没有特别偏离其他数据的样本，且数据在前面的步骤经过预处理。综上所述，选用 K 均值算法有一定的合理性。

第二步：下面以无风化的铅钡玻璃举例，论证其敏感性。类别标签和聚类中心（见表 9 和表 10 保留两位小数）为聚类中心处理采取类别标签+1 分组。

表 9 合理性检验类别标签

k 值	类别标签											
2	1	1	1	1	0	0	0	0	0	0	0	1
4	1	1	3	3	2	2	2	2	2	2	3	3
5	0	0	3	3	2	2	2	2	2	2	1	1

表 10 合理性检验聚类中心

k 值	聚类中心							
2 值	63.15	0.92	0.16	0.71	0.61	3.10	0.72	
1 组	0.77	19.8	7.27	0.51	0.27	0.00	0.46	
2 值	37.92	0.54	0.42	2.07	0.3	3.34	1.27	
2 组	2.82	29.66	15.67	1.53	0.35	0.17	0.00	
4 值	34.65	0.00	0.36	0.24	0.00	3.52	0.76	
1 组	6.62	19.22	24.89	2.95	0.46	0.00	0.00	
4 值	51.92	2.46	0.18	0.67	0.76	3.10	0.00	
2 组	0.76	27.86	9.08	0.22	0.43	0.00	0.00	
4 值	66.41	0.44	0.12	0.80	0.44	2.83	0.96	0.79
3 组	17.96	6.47	0.63	0.14	0.00	0.61		
4 值	35.64	0.00	0.71	4.37	0.75	4.11	2.43	
4 组	0.00	38.48	10.32	0.71	0.42	0.42	0.00	
5 值	66.41	0.44	0.12	0.8	0.44	2.83	0.96	
1 组	0.79	17.96	6.47	0.63	0.14	0.00	0.61	
5 值	35.64	0.00	0.71	4.37	0.75	4.11	2.43	
2 组	0.00	38.48	10.32	0.71	0.42	0.42	0.00	
5 值	37.36	0.00	0.71	0.00	0.00	5.45	1.51	
3 组	4.78	9.30	23.55	5.75	0.00	0.00	0.00	
5 值	51.92	2.46	0.18	0.67	0.76	3.10	0.00	
4 组	0.76	27.86	9.08	0.22	0.43	0.00	0.00	
5 值	31.94	0.00	0.00	0.47	0.00	1.59	0.00	
5 组	8.46	29.14	26.23	0.14	0.91	0.00	0.00	

当我们取 k=2，发现样本被简单地归为两类，有可能差异较大的样本在同一亚类里，不符合“类内距离最小化”的宗旨。如果取 k=4 或 5，结果如下图，可能显得聚类中心差异不够大，并且出现有些样本单独成一亚类的情况，不符合“类间距离最大化”的宗旨。

据此，我们可以推断，模型对 k 值的选取是敏感的。

4.3. 问题三模型的建立与求解

4.3.1. 对未知类别玻璃文物的化学成分分析

对于未知样本为了比较其所属类别，我们小组认为欧式距离+最近邻算法（程序见附录 7）简单方便，以简单易懂的欧氏距离建立与所属类别的联系，再用最近邻算法确定其所属类别（见图 13）。




图 13 最近邻算法的简单描绘

操作步骤如下：

Step1: 利用公式计算其欧氏距离

$$d(x,y):=\sqrt{(x_1-y_1)^2+(x_2-y_2)^2+\cdots+(x_n-y_n)^2}=\sqrt{\sum_{i=1}^n(x_i-y_i)^2}\tag{6}$$

计算出的欧氏距离（见表 11 结果保留两位小数）

表 11 未知文物样本的欧氏距离

文物编号		欧氏距离						
A1	20.94	11.23	15.52	3.61	54.64	23.71	47.46	
A2	44.78	59.29	48.31	53.32	32.95	36.95	19.57	
A3	50.16	65.87	54.27	59.58	31.00	41.75	18.22	
A4	38.14	55.62	42.61	48.59	20.42	33.40	16.50	
A5	18.21	25.49	17.71	18.55	39.73	12.65	29.92	
A6	35.07	11.93	28.70	18.04	66.71	32.96	58.46	
A7	32.52	10.15	26.18	15.22	64.71	31.12	56.51	
A8	29.49	41.72	31.95	35.03	21.79	18.47	15.51	

Step2: 最近邻距离算法（见图 14）

● k-最近邻分类算法

1: 令k是最近邻数目，D是训练样例的集合

2: for 每个测试样例 $z = (x', y')$ do

3: 计算z和每个样例 $(x, y) \in D$ 之间的距离 $d(x', x)$

计算开销大

4: 选择离z最近的k个训练样例的集合 D_z D

5: $y' = \operatorname{argmax}_v \sum_{(x_i, y_i) \in D_z} I(v = y_i)$

两种特殊的数据结构提前对训练集进行优化存储

6: end for

- Kd-Tree
- Kd-Ball

● 距离加权表决

$$y' = \operatorname{argmax}_v \sum_{(x_i, y_i) \in D_z} w_i \times I(v = y_i)$$

图 14 最近邻距离算法

为了更精细化科学化我们在大类型划分之后又进行了亚类划分（亚类划分说明见表 8）得出结论（见表 12）

表 12 未知文物样品划分结果

文物编号	大类型	亚类
A1	高钾	G4
A2	铅钡	Q3
A3	铅钡	Q3
A4	铅钡	Q3
A5	铅钡	Q2
A6	高钾	G2
A7	高钾	G2
A8	铅钡	Q3

4.3.2. 分类结果敏感性分析

我们认为其敏感性在于待测文物完全取决于与其最近的类别，对于这个类别很敏感。如下图（见图 15），此时不易判定类别。



图 15 分类结果敏感性分析举例图

以欧式距离为度量的距离最近的是高钾类，但是路线更多的铅钡类。为此我们尝试选用 K 近邻算法检测模型，取近邻数量为 3，观察文物关于高钾/铅钡的分类，是否与预先分出的亚类相符合。

根据算法，三个类别中数量较多的类作为结果（见表 16）

表 16 未知文物的临近类别

未知类别的文物	邻近类别			
A1	G4	G2	G3	
A2	Q3	Q1	Q2	
A3	Q3	Q1	Q2	
A4	Q3	Q1	Q2	
A5	Q2	G3	G1	
A6	G2	G4	G3	
A7	G2	G4	G3	
A8	Q3	Q2	Q1	

例如[“高钾”“铅钡”“高钾”]，则取“高钾”作为最后结果。于是得出如下分类：A1：高钾 A2：铅钡 A3：铅钡 A4：铅钡 A5：高钾 A6：高钾 A7：高钾 A8：铅钡。经过对比，我们发现 A5 的分类“高钾”与之前的结果“铅钡”不同，其它结果都一致，最近邻模型得出的大部分结果具有可信度、敏感性。

4. 4. 问题四模型的建立与求解

4. 4. 1. 玻璃文物样品化学成分之间的联系

面对关联关系类问题，可使用相关性类的算法模型。为了对比更明确，我们小组选择了一一对比的皮尔逊相关系数用于度量两个变量 X 和 Y 之间的相关（线性相关），其值介于-1 与 1 之间（程序见附录 8）。

以下为皮尔逊系数公式简化：

$$\begin{aligned} r_{xy} &= \frac{\sum Z_x Z_y}{N} \\ &= \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\left(\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \right) \left(\sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2} \right)} \end{aligned} \tag{7}$$

我们利用简单的相关系数分类（见表 17）与实验数据进行对比（见表 18）

表 17 简单的相关系数分类

相关性	相关系数
极强相关	0.8—1.0
强相关	0.6—0.8
中等程度相关	0.4—0.6
弱相关	0.2—0.4
极弱相关或无相关	0.0—0.2

表 18 皮尔逊相关系数

玻璃文物样品类别	化学元素变量	相关系数	相关性
G1	SiO ₂ 和 K ₂ O	-0.58	中等程度相关
	SiO ₂ 和 PbO	-0.14	极弱相关或无相关
	SiO ₂ 和 BaO	0.23	弱相关
	K ₂ O 和 PbO	-0.17	极弱相关或无相关
	K ₂ O 和 BaO	-0.67	强相关
	PbO 和 BaO	0.84	极强相关
G2	SiO ₂ 和 K ₂ O	-1.00	极强相关
	SiO ₂ 和 PbO	1.00	极强相关
	SiO ₂ 和 BaO	0.00	极弱相关或无相关
	K ₂ O 和 PbO	-1.00	极强相关
	K ₂ O 和 BaO	0.00	极弱相关或无相关
	PbO 和 BaO	0.00	极弱相关或无相关

续表

玻璃文物样品类别	化学元素变量	相关系数	相关性
G3	SiO ₂ 和 K ₂ O	0.32	弱相关
	SiO ₂ 和 PbO	0.72	强相关
	SiO ₂ 和 BaO	0.17	极弱相关或无相关
	K ₂ O 和 PbO	0.36	弱相关
	K ₂ O 和 BaO	0.01	极弱相关或无相关
	PbO 和 BaO	0.46	中等程度相关
G4	SiO ₂ 和 K ₂ O	0.00	极弱相关或无相关
	SiO ₂ 和 PbO	0.00	极弱相关或无相关
	SiO ₂ 和 BaO	0.00	极弱相关或无相关
	K ₂ O 和 PbO	0.00	极弱相关或无相关
	K ₂ O 和 BaO	0.00	极弱相关或无相关
	PbO 和 BaO	0.00	极弱相关或无相关
Q1	SiO ₂ 和 K ₂ O	1.00	极强相关
	SiO ₂ 和 PbO	-1.00	极强相关
	SiO ₂ 和 BaO	-1.00	极强相关
	K ₂ O 和 PbO	-1.00	极强相关
	K ₂ O 和 BaO	-1.00	极强相关
	PbO 和 BaO	1.00	极强相关
Q2	SiO ₂ 和 K ₂ O	0.02	极弱相关或无相关
	SiO ₂ 和 PbO	0.04	极弱相关或无相关
	SiO ₂ 和 BaO	-0.82	极强相关
	K ₂ O 和 PbO	-0.22	弱相关
	K ₂ O 和 BaO	0.36	弱相关
	PbO 和 BaO	-0.21	弱相关
Q3	SiO ₂ 和 K ₂ O	-0.53	中等程度相关
	SiO ₂ 和 PbO	-0.95	极强相关
	SiO ₂ 和 BaO	-0.5	中等程度相关
	K ₂ O 和 PbO	0.41	中等程度相关
	K ₂ O 和 BaO	0.43	中等程度相关
	PbO 和 BaO	0.27	弱相关

为了突出其相关性我们用不同颜色标出其相关程度。采用以下原则（见表 19）：

表 19 相关度颜色表

相关性	颜色
极强相关	红色
强相关	橙色
中等程度相关	绿色
弱相关	蓝色
极弱相关或无相关	紫色

4.4.2. 比较不同化学成分之间的差异性

我们对上述数据进行可视化，方便进行直观分析，由此可以看出很多差异性信息（见图 16）。例如： SiO_2 和 PbO 成分关联在 G1 类中成较弱的负相关，在 G2 类成正相关； K_2O 和 B_2O 成分关联在 Q1 类成强烈的负相关，在 Q2 中成较弱的负相关； SiO_2 和 B_2O 成分关联 G3 相关性较弱，在 Q2 中相关性较强。




图 16 化学元素差异性折线图

5. 模型的评价与推广

5.1. 模型的评价

5.1.1. 运用斯皮尔曼相关系数计算

优点：此方法可以将纹饰，类别和颜色转换成等级计算，并且数据可以不服从正态分布规律。

缺点：精确度低于积差相关数据的计算。

5.1.2. 运用独立性样本 t 检验和绘制频率直方图的方法

优点：可以比较两组不相关数据之间的规律，处理样本数量很小的情况，避免了不同实验处理顺序造成的误差。

使用频率直方图来显示此规律，使规律更加明显，便于理解。

缺点：数据要满足正态分布，具有方差齐性。

5.1.3. 运用拉格朗日插值法

优点：能保证所有的多项式都是齐次的。当样本点数量少时，可以插入多个值并拟合出曲线。

缺点：当插值点比较多时，拉格朗日插值多项式的次数可能会很高，因此具有数值不稳定的特点。

5.1.4. 运用主成分分析法

优点：将多个成分进行比较，精确表现各个成分权重。

缺点：仍有少部分化学元素未考虑到。

5.1.5. 运用 k 均值聚类算法

优点：将原本的高钾，铅钡类型进行更加细致的划分（分为七类），使亚类划分更加精细。

缺点：未考虑风化后的样本。

5.1.6. 运用最近邻算法

优点：准确度高，简单直观。

缺点：样本不平衡。

5.1.7. 皮尔逊相关系数

优点：一一对比更能细致看出化学元素的相关性。

缺点：因为更细致的亚类划分且为了科学比较化学成分导致样本数量少，有误差。

5.2. 模型的推广

该模型可用于生活实际的评价类问题以及预测类问题，便于计算机求解，现已成功运用于铁路交通预测、文物保护、最短路径筛选、货物种类统计等，有较强的推广性。

6. 参考文献

[1]张伟锋. 斯皮尔曼简捷相关系数与基尼伽玛相关系数的统计特性分析[D]. 广东工业大学, 2020. DOI:10.27029/d.cnki.ggdgu.2020.001333.

[2]高艺祥, 杨民红, 李兰会. 独立样本 t 检验的 Excel 和 SPSS 分析[J]. 畜牧与饲料科学, 2018, 39(10):79-82. DOI:10.16003/j.cnki.issn1672-5190.2018.10.019.

[3]宋晓蛟. 拉格朗日插值法在预测建筑离散沉降中的应用[J]. 测绘与空间地理信息, 2022, 45(08):250-252+255+258.

[4]李霖, 王琨, 刘强, 刘庆, 谭祥勇. 基于 CNN 的赣江水质时空规律分析与预测[C]//. 2021 年（第七届）全国大学生统计建模大赛获奖论文集（二）.[出版者不详], 2021:898-923.

[5]吉兴全, 韩国正, 李可军, 傅荣荣, 朱仰贺. 基于密度的改进 K 均值聚类算法在配网区块划分中的应用[J]. 山东大学学报(工学版), 2016, 46(04):41-46.

[6]杨太平. 利用 K-最近邻算法的就业数据预测模型[J]. 集成电路应用, 2021, 38(08):124-125. DOI:10.19339/j.issn.1674-2583.2021.08.053.

[7]彭海. 皮尔逊相关系数应用于医学信号相关度测量[J]. 电子世界, 2017(07):163. DOI:10.19353/j.cnki.dzsj.2017.07.129.